

Aula 2: Algoritmo de Metropolis-Hastings

Prof. Dr. Eder Angelo Milani

30/06/2023

Métodos Monte Carlo via Cadeia de Markov

Métodos de Monte Carlo via Cadeia de Markov (MCMC) abrangem uma estrutura geral de métodos introduzidos por Metropolis et. al (1953) e Hastings (1970) para integração de Monte Carlo.

A abordagem MCMC para amostrar da $f(\cdot)$ é construir uma cadeia de Markov com distribuição estacionária $f(\cdot)$ e executá-la por um tempo suficientemente longo, até que ela convirja (aproximadamente) para a distribuição estacionária.

Obs.: Seja X_0, X_1, \dots , um processo estocástico com espaço de estados finito ou infinito enumerável.

Propriedade de Markov: a probabilidade de que a cadeia assuma um certo valor futuro, quando o seu estado atual é conhecido, não se altera, caso seja conhecido o seu comportamento passado.

Em termos probabilístico, temos que

$$P(X_{t+1} = y | x_t, x_{t-1}, \dots) = P(X_{t+1} = y | x_t)$$

O objetivo é gerar valores de uma distribuição $p(\cdot)$ simulando uma cadeia de Markov.

O Algoritmo de Metropolis-Hastings

Os algoritmos de Metropolis-Hastings são uma classe dos métodos de Monte Carlo via cadeia de Markov, incluindo os casos especiais do amostrador de Metropolis, amostrador de Gibbs e o passeio aleatório.

A principal ideia é gerar uma cadeia de Markov $\{x_t, t = 0, 1, \dots\}$ tal que sua distribuição estacionária é a distribuição desejada. O algoritmo deve especificar, para um determinado estado x_t , como gerar o próximo estado x_{t+1} . Em todos os algoritmos de amostragem Metropolis-Hastings (M-H) existe um valor candidato y gerado a partir de uma distribuição de posposta $g(\cdot | x_t)$. Se o valor candidato é aceito, a cadeia se move para o estado y no tempo $t + 1$ e $x_{t+1} = y$; caso contrário, a cadeia permanece no estado x_t e $x_{t+1} = x_t$. *Note que a distribuição de proposta pode depender do estado anterior x_t .*

A escolha da distribuição de proposta é muito flexível, mas a cadeia gerada por essa escolha deve satisfazer certas condições de regularidade. A distribuição de proposta deve ser escolhida para que a cadeia gerada convirja para uma distribuição estacionária (a distribuição desejada f). Uma distribuição de proposta com o mesmo suporte da distribuição desejada usualmente satisfaz as condições de regularidade.

Amostrador de Metropolis-Hastings

O amostrador de Metropolis-Hastings gera uma cadeia de markov $\{x_0, x_1, \dots\}$ como a seguir

1- Escolha a distribuição de proposta $g(\cdot | x_t)$.

2 - Gerar x_0 da distribuição g .

3 - Repetir

- (a) gerar y da distribuição $g(.|x_t)$;
- (b) gerar u da distribuição uniforme(0,1);
- (c) se $u \leq \frac{f(y)g(x_t|y)}{f(x_t)g(y|x_t)}$ aceitar y e adotar $x_{t+1} = y$, caso contrário, $x_{t+1} = x_t$;
- (d) incrementar t .

obs.:

- (i) As repetições devem ocorrer até que a cadeia convirja para a distribuição estacionária de acordo com algum critério.
- (ii) No passo 3(c) o valor y é aceito com probabilidade

$$\alpha(x_t, y) = \min\left(1, \frac{f(y)g(x_t|y)}{f(x_t)g(y|x_t)}\right),$$

assim é necessário apenas conhecer a densidade da distribuição desejada a menos de uma constante.

Assumindo que a distribuição de proposta satisfaz as condições de regularidade, a cadeia M-H irá convergir para a única distribuição estacionária π . O algoritmo é projetado para que a distribuição estacionária da cadeia M-H seja realmente a distribuição desejada, f .

Exemplo 1 Faça o que se pede a seguir

- (1) Gerar uma amostra de tamanho 200 da distribuição Bernoulli($\theta = 0.3$).
- (2) Utilizando a abordagem Bayesiana, considere a distribuição a priori como Beta($\alpha = 2, \beta = 2$), obtenha uma cadeia de Markov com 11 mil valores da distribuição a posteriori.
- (3) Obtenha uma mostra aleatória de 1.000 valores da distribuição a posteriori.
- (4) Compare graficamente as distribuições teórica e amostrada.
- (5) Obtenha a partir da amostra a estimativa pontual adotando a função perda quadrática, compare com o valor teórico.

Solução:

```
set.seed(2023)
n <- 100
theta=0.3
z <- rbinom(n, 1, theta)
table(z)
```

```
## z
##  0  1
## 67 33
```

A distribuição a priori é $h(\theta) \propto \theta(1 - \theta)$, combinando com a função de verossimilhança $L(\theta|\underline{z}) \propto \theta^{\sum z_i} (1 - \theta)^{200 - \sum z_i}$, tem se

$$h(\theta|\underline{z}) \propto h(\theta)L(\theta|\underline{z}) \propto \theta^{1+\sum z_i} (1 - \theta)^{1+200-\sum z_i}.$$

Vamos adotar que a geração do candidato será realizada utilizando a distribuição Uniforme(0,1). Logo o valor y é aceito com probabilidade

$$\alpha(x_t, y) = \min\left(1, \frac{f(y)g(x_t|y)}{f(x_t)g(y|x_t)}\right),$$

note que a distribuição f é a densidade a posteriori, no entanto não temos a forma fechada, mas sabemos que existe uma constante k tal que

$$h(\theta|\underline{z}) = k\theta^{1+\sum z_i} (1 - \theta)^{1+200-\sum z_i},$$

logo

$$\alpha(x_t, y) = \min\left(1, \frac{h(y|\underline{z})g(x_t|y)}{h(x_t|\underline{z})g(y|x_t)}\right) = \min\left(1, \frac{ky^{1+\sum z_i} (1 - y)^{1+200-\sum z_i}}{kx_t^{1+\sum z_i} (1 - x_t)^{1+200-\sum z_i}}\right),$$

note que podemos eliminar a constante k da última expressão, ou seja, não é necessário conhecer a constante que normaliza a distribuição a posteriori. Observe também, que na equação acima, foi substituído a expressão da geradora de candidato.

```
set.seed(2023)

## definindo o calculo da razao
razao = function(amostra, x, y){
  n <- length(amostra)
  numerador <- y^(1+ sum(amostra))*(1-y)^(1+n- sum(amostra))
  denominador <- x^(1+ sum(amostra))*(1-x)^(1+n- sum(amostra))
  return(numerador/denominador)
}

tamanho = 11000
x = numeric(tamanho)
x[1] = runif(1)
x[1]
```


```
## [1] 0.4666139
```

```
for (t in 2:tamanho){
  y = runif(1)
  u = runif(1)
  x[t]=ifelse(u <= razao(z, x[t-1], y), y, x[t-1])
}


summary(x)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.1745 0.3048 0.3363 0.3364 0.3665 0.5211
```


```
# grafico dos valores gerados  
plot(seq(1,tamanho), x, type = "l")
```



```
plot(seq(1,100), x[1:100], type = "l")
```



```
# desconsiderar as primeiras 1000 observações - eliminar o efeito do valor inicial  
plot(seq(1001,tamanho), x[1001:tamanho], type = "l")
```




```
# quantidade de rejeições  
1-length(unique(x))/tamanho
```

```
## [1] 0.8547273
```


```
# calcular a correlacao na cadeia  
acf(x)
```

Series x




```
# calcular a correlacao na cadeia excluindo os primeiros 1000 valores  
acf(x[1001:tamanho])
```

Series x[1001:tamanho]




```
# amostra aleatoria - pegando os valores 1001, 10011, 10021, ...  
amostra=x[seq(1001,tamanho,by=10)]  
  
# calculo da acf para a amostra  
acf(amostra)
```


Series amostra



```
# plot da amostra independente  
plot(seq_along(amostra), amostra, type = "l")
```



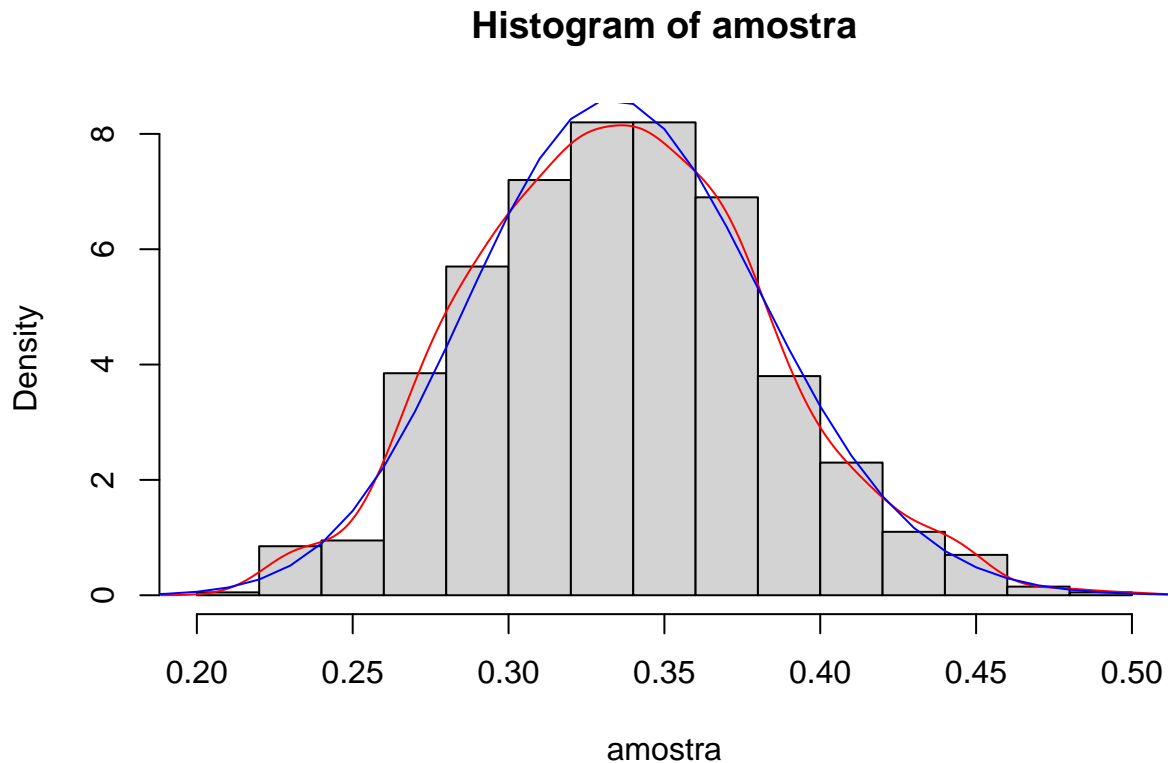
```
# resumo da amostra
summary(amostra)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.2199 0.3021 0.3360 0.3359 0.3665 0.4986
```

```
# comparação com o valor teórico
```

Sabemos que a distribuição a posteriori é uma $\text{Beta}(\alpha + \sum x_i, \beta + n - \sum x_i)$, ou seja, $\text{Beta}(35, 69)$. A comparação gráfica pode ser feita utilizando o código a seguir.

```
hist(amostra, freq = F)
lines(density(amostra), col="red")
theta_aux <- seq(0.01, 0.99, 0.01)
lines(theta_aux, dbeta(theta_aux, 35, 69), col="blue")
```



Sabemos que a média a posteriori é a estimativa pontual quando utilizamos a função perda quadrática. Para o caso da distribuição $\text{Beta}(\alpha, \beta)$, a média a posteriori é $\alpha/(\alpha + \beta)$, para este exemplo, tem-se $E(\theta|\underline{z}) = 35/(69 + 35) = 35/104 = 0,3365$. O resultado utilizando a amostra da distribuição a posteriori é

```
mean(amostra)
```

```
## [1] 0.3359213
```

Exercícios para a próxima aula prática

Exercício 1 Simule uma amostra aleatória de tamanho 30 da distribuição $\text{Poisson}(\lambda = 4)$. Considerando a distribuição a priori como $\text{Gama}(\alpha = 2, \beta = 2)$, obtenha uma cadeia de Markov de 11 mil valores da distribuição a posteriori. Obtenha uma amostra aleatória de tamanho 1.000 da distribuição a posteriori. Compare as estimativas obtidas pela amostra com os resultados teóricos usando gráficos e medidas resumo.

Exercício 2 Seja X_1, \dots, X_n uma amostra aleatória da distribuição $\text{Normal}(\mu, \sigma^2)$, sendo que $\sigma^2 = 1$. Considerando como distribuição a priori para o parâmetro μ a t -Student com $v = 4$ graus de liberdade, obtenha uma cadeia de Markov de 21 mil valores da distribuição a posteriori. Obtenha uma amostra aleatória de tamanho 1.000 da distribuição a posteriori. Compare as estimativas obtidas pela amostra com os resultados teóricos usando gráficos e medidas resumo.